Fatores Associados à Autopercepção de Saúde na PNS: Uma Análise Baseada em Modelos Estatísticos e Aprendizado de Máquina

Vinícius Henrique Giovanini[1], **Luis Enrique Zarate Galvez**[1]

[1]Programa de Pós-graduação em Informática
Pontifícia Universidade Católica de Minas Gerais (PUCMG)
Belo Horizonte – MG – Brasil

viniciushenriquegiovanini@gmail.com

zarate@pucminas.br

Abstract. *This work presents an analysis of the factors associated with self-perceived health using data from the 2019 Brazilian National Health Survey (PNS), with a focus on interpreting the phenomenon and identifying relevant variables. Initially, variables were manually selected based on the literature. Subsequently, an ordinal logistic regression model was employed to assess the statistical contribution of these variables in explaining the response variable. Additionally, machine learning–based models, including decision trees and the CatBoost algorithm, were used as exploratory tools for analyzing variable importance and identifying patterns in the data. Based on the results obtained, the role of key socioeconomic, demographic, and health-related determinants in individuals' self-perceived health is discussed.*

Resumo. *Este trabalho apresenta uma análise dos fatores associados à autopercepção de saúde a partir dos dados da Pesquisa Nacional de Saúde (PNS) do ano de 2019, com foco na interpretação do fenômeno e na identificação de variáveis relevantes. Inicialmente, foram selecionadas variáveis de maneira manual com base na literatura. Em seguida, empregou-se um modelo de regressão logística ordinal para avaliar a contribuição estatística dessas variáveis na explicação da variável resposta. Complementarmente, modelos baseados em aprendizado de máquina, incluindo árvores de decisão e o algoritmo CatBoost, foram utilizados como ferramentas exploratórias para análise de importância das variáveis e identificação de padrões nos dados. A partir dos resultados obtidos, discute-se o papel dos principais determinantes socioeconômicos, demográficos e de condições de saúde na autopercepção dos indivíduos.*

1. Introdução

A autopercepção de saúde é amplamente utilizada como indicador do estado de saúde da população, estando associada a desfechos como morbimortalidade, uso de serviços de saúde e qualidade de vida. Por ser uma medida subjetiva, reflete não apenas condições clínicas, mas também fatores socioeconômicos, demográficos e contextuais. No contexto da Pesquisa Nacional de Saúde (PNS), essa variável é mensurada em uma escala ordinal

de cinco categorias, de muito boa a muito ruim, permitindo captar diferentes gradientes de percepção que se perdem em abordagens binárias. Assim, análises que respeitam sua natureza ordinal possibilitam uma compreensão mais precisa dos fatores associados aos distintos níveis de avaliação da saúde.

Compreender como diferentes fatores se relacionam com os distintos níveis de autopercepção de saúde constitui um aspecto central desse trabalho, especialmente diante da complexidade dessa medida subjetiva. Em vez de focar exclusivamente no desempenho preditivo de modelos, o estudo propõe uma abordagem interpretativa, voltada à identificação dos padrões e relações subjacentes aos dados, de modo a evidenciar quais variáveis exercem maior influência em cada nível de avaliação da saúde. Essa perspectiva é particularmente relevante no campo da saúde pública, uma vez que a compreensão dos determinantes associados à percepção de saúde pode subsidiar a formulação de políticas públicas e estratégias de intervenção mais direcionadas.

Este trabalho tem como objetivo identificar e analisar os fatores que melhor descrevem a autopercepção de saúde por meio de modelos estatísticos e técnicas de aprendizado de máquina supervisionadas e não supervisionadas. Como visto no diagrama presente na Figura 1, foi realizado um pré-processamento da base de dados fundamentado em artigos da literatura, com o objetivo de reduzir a dimensionalidade e mitigar o problema da explosão combinatória, o qual pode inviabilizar a extração de conhecimento por modelos de *machine learning*. Em seguida, foi empregado um modelo de regressão logística ordinal, com a finalidade de avaliar a relação estatística entre as variáveis explicativas e a variável resposta ordinal, correspondente à autoavaliação do estado de saúde. Ressalta-se que, nessa etapa, o modelo não foi utilizado com fins preditivos, mas sim como uma ferramenta exploratória e analítica para o ranqueamento das variáveis, permitindo a identificação daquelas com maior significância estatística sobre o fenômeno.

Figura 1. Fluxo geral do processamento e da aplicação de algoritmos

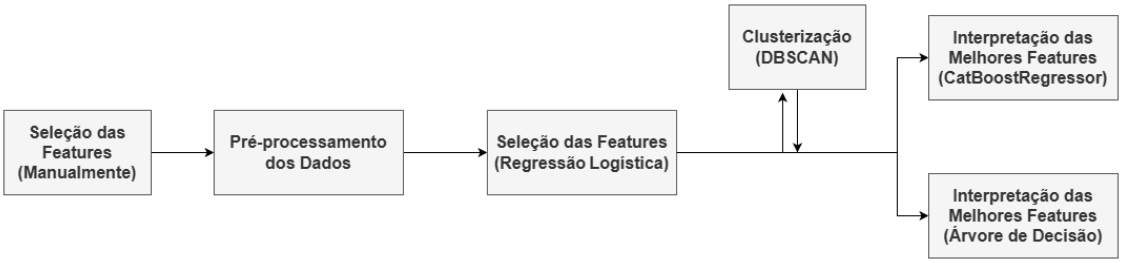

As variáveis selecionadas a partir dessa análise foram posteriormente utilizadas como entrada para modelos baseados em árvores, e também possibilitando um segundo experimento, adicionando uma etapa de clusterização com DBSCAN para selecionar os melhores registros e utiliza-los como entrada nos algoritmos de *machine learning*. Inicialmente, empregou-se o algoritmo de Árvore de Decisão, entretanto, por se tratar de um problema de natureza ordinal, no qual a ordem entre as categorias da variável resposta é relevante, optou-se também pelo uso do *CatBoostRegressor*. Esse algoritmo, embora baseado em árvores, permite tratar a variável alvo de forma contínua e ordinal, penalizando erros de maior magnitude de maneira mais severa. Dessa forma, o *CatBoostRegressor* foi

adotado como modelo principal para a análise da importância das variáveis, possibilitando a identificação das *features* que mais impactam a autoavaliação do estado de saúde.

2. Trabalhos Relacionados

A autoavaliação do estado de saúde tem sido amplamente investigada na literatura como um importante indicador subjetivo de saúde populacional, associado tanto a fatores sociodemográficos quanto a comportamentos relacionados ao estilo de vida. Estudos iniciais com dados nacionais brasileiros, como [Szwarcwald et al. 2015], analisaram os determinantes da autoavaliação de saúde a partir da Pesquisa Nacional de Saúde (PNS/2013), evidenciando que comportamentos saudáveis, como prática regular de atividade física, alimentação adequada e não tabagismo, exercem influência significativa sobre a percepção positiva da saúde. Os autores destacam que a autoavaliação de saúde reflete não apenas condições clínicas objetivas, mas também aspectos sociais e comportamentais, reforçando sua relevância como variável resposta em estudos epidemiológicos. Em continuidade a essa linha de pesquisa, o trabalho [Triaca et al. 2017] aprofundou-se ao avaliar a influência combinada de múltiplos estilos de vida saudáveis sobre a probabilidade de os indivíduos classificarem sua saúde como boa. Utilizando regressão logística aplicada a uma amostra representativa da população brasileira, os autores demonstraram que a adoção simultânea de comportamentos saudáveis aumenta substancialmente as chances de uma autoavaliação positiva da saúde.

Posteriormente, a pesquisa [Ferrari Junior et al. 2021] ampliou-se essa discussão ao investigar fatores socioambientais e comportamentais associados à autoavaliação negativa de saúde no Brasil. Os resultados evidenciaram que desigualdades sociais, condições ambientais desfavoráveis e hábitos não saudáveis estão fortemente associados a percepções negativas do estado de saúde. Esse estudo reforça a necessidade de abordagens analíticas capazes de lidar com múltiplas variáveis explicativas e relações não lineares, uma vez que o impacto desses fatores pode variar conforme o contexto social e econômico dos indivíduos.

Mais recentemente, avanços metodológicos têm incorporado técnicas de *machine learning* para modelar a autoavaliação de saúde de forma mais robusta. [Zong et al. 2025] utilizaram diferentes algoritmos de aprendizado de máquina, incluindo o *CatBoost* para prever a autoavaliação de saúde em fases mais avançadas da vida. Os autores demonstraram que modelos baseados em árvores e *boosting* apresentam desempenho superior em comparação a abordagens estatísticas tradicionais, além de possibilitarem a identificação das variáveis mais relevantes por meio de medidas de importância das *features*. Esse estudo evidencia o potencial de algoritmos como o *CatBoost* para capturar relações não lineares e interações complexas entre variáveis explicativas, especialmente em problemas de natureza ordinal, como a autoavaliação do estado de saúde.

3. Referencial Teórico

O trabalho utiliza técnicas de aprendizado de máquina supervisionadas e não supervisionadas para identificar padrões entre variáveis socioeconômicas, comportamentais e de saúde. Entre os métodos supervisionados, empregam-se árvores de decisão, *CatBoost* e regressão logística. Já o DBSCAN, que engloba a classe de métodos não supervisionados, é utilizado para explorar a estrutura dos dados, identificar agrupamentos e detectar possíveis *outliers* sem variável alvo.

A regressão logística ordinal é utilizada para modelar variáveis dependentes com categorias ordenadas, estimando a probabilidade de pertencimento a cada nível da resposta. Diferentemente da versão binária, considera a ordem natural das classes por meio de funções de ligação como *logit* ou *probit*. É especialmente adequada para fenômenos subjetivos, como a autoavaliação de saúde, permitindo analisar a influência dos preditores nos diferentes níveis de percepção.

A regressão logística ordinal é comumente formulada por meio do modelo de chances proporcionais. Seja Y uma variável resposta ordinal com K categorias ordenadas $(1, 2, \ldots, K)$ e $\mathbf{x}$ um vetor de variáveis explicativas. O modelo define a probabilidade acumulada de Y assumir uma categoria menor ou igual a k como:

$$\log\left(\frac{P(Y \leq k \mid \mathbf{x})}{P(Y > k \mid \mathbf{x})}\right) = \theta_k - \mathbf{x}^\top \boldsymbol{\beta}, \quad k = 1, \ldots, K-1, \tag{1}$$

onde θ_k representa os parâmetros de corte (*thresholds*) entre as categorias e $\boldsymbol{\beta}$ é o vetor de coeficientes associado às variáveis explicativas.

Nesse modelo, o sinal e a magnitude dos coeficientes em $\boldsymbol{\beta}$ indicam o efeito das variáveis explicativas sobre a probabilidade de o indivíduo pertencer a categorias mais elevadas ou mais baixas da variável resposta, assumindo que o efeito das covariáveis é constante ao longo dos pontos de corte.

As árvores de decisão são modelos supervisionados amplamente utilizados para tarefas de classificação e regressão, baseando-se na divisão recursiva do espaço de atributos em regiões mais homogêneas em relação à variável resposta. No caso da classificação, o algoritmo busca selecionar, em cada nó, a variável explicativa e o ponto de corte que maximizam a pureza dos subconjuntos gerados. Formalmente, seja $\mathcal{D}$ o conjunto de dados em um nó, a impureza pode ser mensurada por métricas como o índice de Gini, definido como:

$$G(\mathcal{D}) = 1 - \sum_{k=1}^{K} p_k^2, \tag{2}$$

onde p_k representa a proporção de observações pertencentes à classe k no conjunto $\mathcal{D}$. A escolha da divisão ótima é realizada minimizando a impureza ponderada dos nós filhos:

$$\Delta G = G(\mathcal{D}) - \sum_{j=1}^{J} \frac{|\mathcal{D}_j|}{|\mathcal{D}|} G(\mathcal{D}_j), \tag{3}$$

em que $\mathcal{D}_j$ denota os subconjuntos resultantes da divisão. Esse processo é repetido de forma recursiva até que critérios de parada sejam atendidos, como profundidade máxima ou número mínimo de observações por nó. A principal vantagem das árvores de decisão reside em sua interpretabilidade, uma vez que as regras de decisão podem ser diretamente analisadas, permitindo compreender como diferentes combinações de variáveis influenciam a classificação da variável resposta.

O *CatBoostRegressor* é um algoritmo baseado em árvores de decisão e *boosting*, eficiente no tratamento de variáveis categóricas e ordinais. Ele constrói árvores sequenci-

ais que corrigem erros anteriores, capturando relações não lineares e interações complexas. Além do bom desempenho preditivo, permite analisar a importância das variáveis para interpretar os fatores associados ao fenômeno.

De forma geral, modelos baseados em *gradient boosting* buscam minimizar uma função de perda $\mathcal{L}$ por meio da combinação aditiva de árvores de decisão:

$$\hat{y}_i = \sum_{m=1}^{M} f_m(\mathbf{x}_i), \quad f_m \in \mathcal{F}, \tag{4}$$

No caso do *CatBoost*, estratégias específicas de codificação ordenada de variáveis categóricas são empregadas para reduzir viés.

Para avaliação de desempenho do algoritmo *CatBoost* foi utilizado o *Quadratic Weighted Kappa* (QWK). O QWK é especialmente adequado para variáveis ordinais, pois penaliza mais fortemente previsões que se afastam significativamente da classe verdadeira, considerando a distância quadrática entre categorias previstas e observadas. A fórmula do QWK é dada por:

$$\kappa_w = 1 - \frac{\sum_{i,j} w_{i,j} O_{i,j}}{\sum_{i,j} w_{i,j} E_{i,j}}$$

onde $O_{i,j}$ representa a matriz de observações entre a classe verdadeira i e a prevista j, $E_{i,j}$ é a matriz de expectativas, e

$$w_{i,j} = \frac{(i-j)^2}{(N-1)^2}$$

é o peso quadrático aplicado a cada par de categorias, com N sendo o número total de classes. Dessa forma, previsões próximas da categoria correta contribuem menos para a penalização do que previsões distantes, refletindo melhor a natureza ordinal do problema.

O DBSCAN é um método de clusterização não supervisionada baseado em densidade, capaz de identificar agrupamentos sem definir previamente o número de *clusters* e de detectar *outliers*. Diferentemente do *k-means*, é robusto a formatos arbitrários e ruídos nos dados. Neste presente estudo, é utilizado de forma exploratória para identificar padrões latentes e perfis distintos relacionados à autopercepção de saúde.

Formalmente, o DBSCAN define a vizinhança ε de um ponto $\mathbf{x}_i$ como o conjunto:

$$N_\varepsilon(\mathbf{x}_i) = \{\mathbf{x}_j \in \mathcal{D} \mid \text{dist}(\mathbf{x}_i, \mathbf{x}_j) \leq \varepsilon\}, \tag{5}$$

onde ε é o raio de vizinhança e *dist* representa uma métrica de distância.

Um ponto é considerado um *core point* se $|N_\varepsilon(\mathbf{x}_i)| \geq \text{MinPts}$.

A partir desses pontos centrais, o algoritmo expande os *clusters* por conectividade de densidade, enquanto pontos que não satisfazem esses critérios são classificados como ruído.

4. Materiais e Métodos

4.1. Base de Dados

A base de dados utilizada neste estudo é a Pesquisa Nacional de Saúde (PNS) 2019, conduzida pelo Instituto Brasileiro de Geografia e Estatística (IBGE) em parceria com o Ministério da Saúde. A pesquisa reúne informações sobre condições de saúde, doenças crônicas, hábitos e percepção subjetiva do estado de saúde da população brasileira, totalizando 293.726 registros e 1.088 atributos. Neste trabalho, a variável de interesse é a autoavaliação do estado de saúde, composta por seis categorias ordinais, podendo ser visualizado na Tabela 1, configurando um problema de classificação ordinal.

A distribuição da variável alvo apresenta desbalanceamento, com maior concentração nas categorias Boa e Regular e menor frequência em Ruim e Muito Ruim conforme visualizado na Figura 2. Não foi aplicado balanceamento artificial, pois essa distribuição reflete o padrão real observado nos 90.846 registros válidos. Ressalta-se que o número total de observações é posteriormente alterado nas etapas de pré-processamento, devido à remoção de registros incompletos.

Tabela 1. Categorias da variável de autoavaliação do estado de saúde

Código	1	2	3	4	5	9
Categoria	Muito Boa	Boa	Regular	Ruim	Muito Ruim	Ignorado

Figura 2. Desbalanceamento da variável alvo presente em 90.846 registros

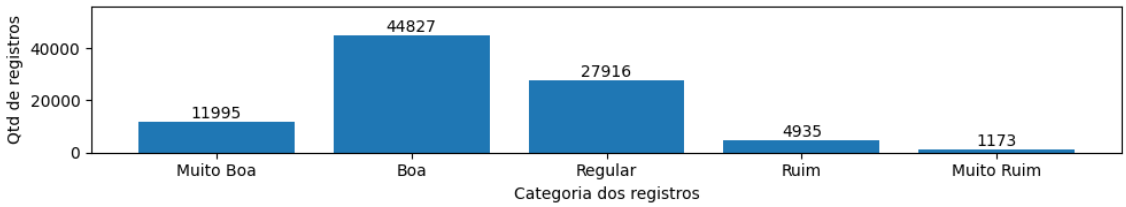

4.2. Metodologia

A metodologia adotada neste trabalho é orientada por um modelo conceitual baseado no artigo [Zárate et al. 2023] e em estudos da literatura, como [Szwarcwald et al. 2015] e [Triaca et al. 2017], que definem os principais tópicos e variáveis essenciais para representar a autoavaliação do estado de saúde de forma consistente. Conforme ilustrado na Figura 3, o modelo organiza os determinantes da saúde em diferentes tópicos, incluindo informações pessoais, condições socioeconômicas, educação, condições financeiras, doenças crônicas, estilo de vida e utilização de serviços de saúde. Guiando a seleção das variáveis exploradas nos modelos de *machine learning* aplicados à PNS 2019. Algumas variáveis conceitualmente relevantes, como indicadores diretos de níveis educacionais ou condições específicas de saúde, não puderam ser incluídas devido à indisponibilidade de dados ou alta proporção de registros ausentes, preservando, assim, a coerência teórica do modelo dentro das limitações da base.

Figura 3. Modelo Conceitual

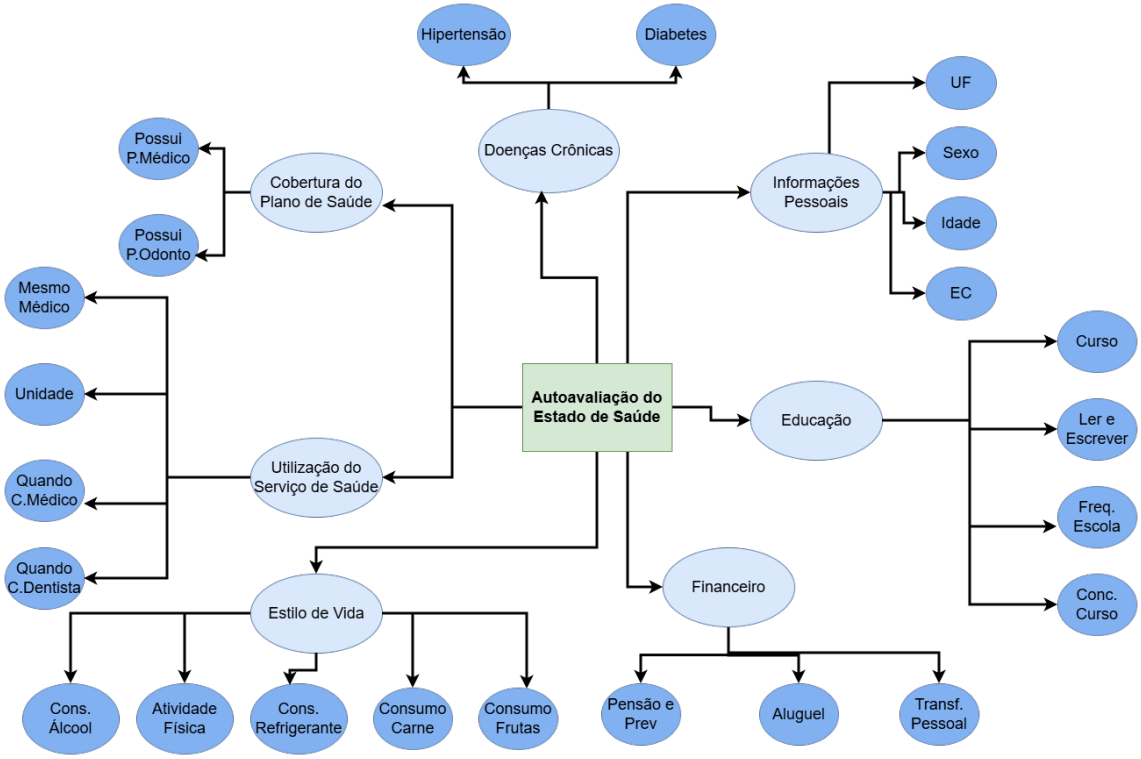

4.2.1. Pré-processamento

A hipótese inicial deste trabalho consistia em selecionar, dentre as 1.088 variáveis disponíveis, aquelas que teriam maior efeito explicativo sobre a autoavaliação do estado de saúde, com base em uma análise da literatura e na seleção manual de *features*. Entretanto, essa abordagem revelou uma limitação importante, muitas das variáveis potencialmente relevantes apresentavam elevados níveis de valores ausentes, o que comprometeria a robustez das análises subsequentes.

Antes da etapa de seleção manual das *features*, o conjunto de dados passou por três etapas de filtragem. A primeira consistiu na exclusão das linhas que não apresentavam valores na coluna alvo, o que reduziu o número de registros de 293.726 para 90.846, uma redução expressiva da base de dados.

A segunda etapa envolveu a remoção das colunas que possuíam mais de 80% de valores ausentes, reduzindo a dimensionalidade do conjunto de dados de 1.088 para 490 colunas, o que representa uma redução aproximada de 55%.

Por fim, foi aplicada uma terceira transformação, que consistiu na exclusão de registros que não haviam respondido a pelo menos 80% das colunas remanescentes (490). No entanto, essa etapa não produziu impacto significativo sobre o conjunto de dados. O resultado final após essas transformações é apresentado na Tabela 2, demonstrando os valores antes e depois, por linha e coluna respectivamente.

Tabela 2. Etapas de filtragem do conjunto de dados (Linhas / Colunas)

Etapa	Antes	Depois
Filtro variável alvo	293.726 / 1.088	90.846 / 1.088
Filtro colunas (NaN $\geq$ 80%)	90.846 / 1.088	90.846 / 490
Filtro linhas (NaN $\geq$ 80%)	90.846 / 490	90.846 / 490

4.2.2. Seleção das Features

A segunda etapa deste trabalho consistiu na seleção manual das variáveis mais relevantes dentre as 490 colunas remanescentes após o pré-processamento. Essa seleção foi orientada pelo modelo conceitual fundamentado em estudos da literatura, que pode ser visto na Figura 3, visando identificar fatores com maior potencial explicativo para a autoavaliação do estado de saúde. Conforme apresentado na Tabela 3, foram selecionadas variáveis relacionadas a aspectos sociodemográficos, socioeconômicos, saúde mental, presença de doenças, estilo de vida e apoio social.

Embora o conjunto de dados da PNS contenha variáveis de educação, essas não foram incluídas na análise devido à elevada proporção de valores ausentes e à complexidade adicional de pré-processamento, especialmente pela presença de respostas dependentes da idade. Ressalta-se que o dataset é particularmente rico em variáveis relacionadas a doenças e condições de saúde, contudo, a seleção dessas variáveis foi realizada de forma criteriosa, a fim de evitar a inclusão de variáveis que pudessem atuar como preditores diretos da variável alvo, introduzindo viés no modelo de aprendizado de máquina. Por esse motivo, também foi evitada a seleção excessiva de *features* associadas a perguntas diretas sobre a existência de problemas de saúde. Outros tipos de variáveis, como aquelas relacionadas à cobertura de plano de saúde e a aspectos financeiros, foram incluídas em menor quantidade, ou estão ausentes, com o objetivo de limitar o número de colunas e, consequentemente, evitar o aumento do custo computacional e da complexidade quando utilizadas com algoritmos de *machine learning*. Ao final dessa etapa, conforme indicado na Tabela 3, o conjunto de dados resultante foi composto por 25 colunas, incluindo a variável alvo.

Tabela 3. Distribuição das variáveis selecionadas por tópico

Tópico	Quantidade de variáveis
Variável alvo	1
Sociodemográfico	5
Socioeconômico	6
Saúde mental	4
Doenças	3
Estilo de vida	4
Apoio social	2
Total	**25**

Na Tabela 4 são apresentadas as 24 variáveis selecionadas, além da variável de autoavaliação do estado de saúde. Essas variáveis foram renomeadas para facilitar a análise, por exemplo, a variável *Grau_Limite_DORT* representa distúrbios osteomuscula-

res relacionados ao trabalho, no *dataset* original da PNS, está nomeada como "Em geral, em que grau o DORT limita as suas atividades habituais", já a variável *Freq_Anedonia* consiste na frequência com que o indivíduo relatou ter sentido pouco interesse ou prazer em realizar atividades cotidianas em um determinado período de referência. Foram selecionadas variáveis que permitem caracterizar diferentes dimensões do respondente, incluindo dados demográficos como idade, sexo, cor/raça e estado civil, informações socioeconômicas como quantidade de cômodos e banheiros, posse de automóvel, computador e acesso à internet, aspectos de qualidade de vida e hábitos, como prática de exercício, horas de televisão, consumo de álcool e tabaco, e saúde mental, abrangendo frequência de problemas de sono, cansaço e depressão. Além disso, foram incluídas três variáveis relacionadas a doenças (*Grau_Limite_Depressao*, *Grau_Limite_Doenca_Mental* e *Grau_Limite_DORT*) que fornecem informações complementares sobre limitações funcionais decorrentes de condições físicas ou mentais, permitindo contextualizar o impacto desses fatores na vida diária dos respondentes.

Tabela 4. Variáveis selecionadas por tópico (duas colunas) - Sem a variável alvo

Variável	Tópico	Variável	Tópico
Idade	Sociodemográfico	Freq_Problemas_Sono	Saúde mental
Sexo	Sociodemográfico	Freq_Cansaco	Saúde mental
Cor_Raca	Sociodemográfico	Freq_Anedonia	Saúde mental
Estado_Civil	Sociodemográfico	Freq_Depressao	Saúde mental
Nivel_Instrucao	Sociodemográfico	Grau_Limite_Depressao	Doenças
Total_Moradores	Socioeconômico	Grau_Limite_Doenca_Mental	Doenças
Qtd_Comodos	Socioeconômico	Grau_Limite_DORT	Doenças
Qtd_Banheiros	Socioeconômico	Pratica_Exercicio	Estilo de vida
Possui_Automovel	Socioeconômico	Horas_TV	Estilo de vida
Possui_Computador	Socioeconômico	Fuma	Estilo de vida
Acesso_Internet	Socioeconômico	Freq_Alcool	Estilo de vida
Apoio_Amigos	Apoio social	Apoio_Familiar	Apoio social

4.2.3. Regressão Logística Ordinal

Nesta etapa do trabalho, as 24 variáveis selecionadas foram inicialmente incorporadas a um modelo de regressão logística ordinal, com o objetivo de avaliar a contribuição individual de cada covariável sobre a autopercepção de saúde. Esse procedimento teve caráter exploratório e interpretativo, sendo utilizado tanto para identificar variáveis com maior impacto ordinal quanto para ajudar em decisões de simplificação do conjunto de atributos empregado posteriormente no modelo de *CatBoost*.

Conforme ilustrado na Figura 4, algumas variáveis apresentaram coeficientes estimados próximos de zero, indicando baixo deslocamento das razões de chance entre as categorias do problema. Destacam-se, nesse grupo, as variáveis Fuma, Horas_TV, Estado_Civil, Apoio_Familiar e Qtd_Comodos, na qual são candidatas para serem removidas em experimentos posteriores.

Figura 4. Coeficientes da Regressão Logística Ordinal

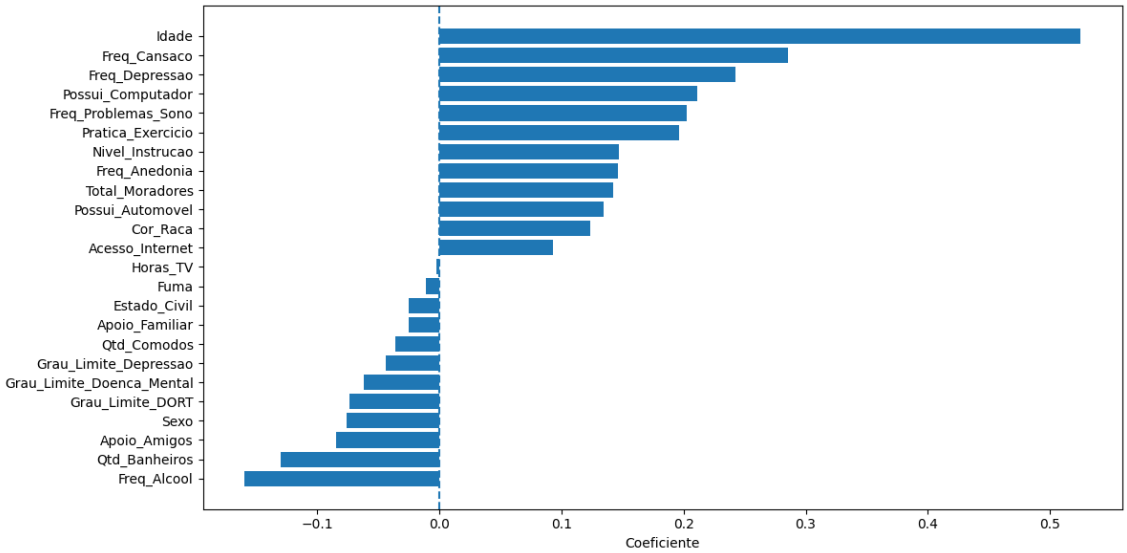

4.2.4. Árvore de Decisão, CatBoostRegressor e DBSCAM

A ideia inicial deste trabalho era utilizar somente árvores de decisão para interpretar as variáveis mais importantes e, assim, descrever o fenômeno estudado. No entanto, ao analisar a literatura, observa-se que [Szwarcwald et al. 2015] tratam a autoavaliação de saúde como uma variável categórica ordinal, o que limita a aplicação de árvores de decisão tradicionais, que normalmente lidam com problemas categóricos nominais. Apesar disso, árvores de decisão foram utilizadas em testes mais simples, com o objetivo de comparar seu desempenho com o do *CatBoost*, um algoritmo de *boosting* adequado para problemas ordinais e capaz de lidar corretamente com a natureza ordenada da variável alvo.

Também foi utilizado o algoritmo DBSCAN, aplicado ao *dataset* pré-processado com o objetivo de identificar e selecionar registros mais coesos, permitindo um comparativo com os resultados obtidos pelo *CatBoostRegressor* com e sem a utilização da clusterização.

5. Experimentos e Resultados

5.1. Árvore de Decisão

O algoritmo de árvore de decisão foi utilizado para motivos comparativos, mesmo não sendo apropriado para o problema em questão. Dessa forma foi aplicado o conjunto de dados pré-processados com 24 *features* mais a variável alvo, totalizando 25 colunas, e com um total de 90.846 registros

Nesse teste, as variáveis categóricas do conjunto de dados foram transformadas em variáveis binárias, de forma a permitir que cada categoria pudesse ser considerada separadamente pelo modelo de aprendizado de máquina. Esse procedimento foi aplicado a variáveis nominais como sexo, cor/raça, estado civil, posse de automóvel, computador, acesso à internet, diagnóstico de doença crônica, prática de exercício e hábito de fumar. Cada categoria passou a ser representada por uma variável própria, preservando a

informação contida nas variáveis originais e evitando redundâncias que pudessem comprometer a interpretação do modelo.

Foi realizado um teste exploratório, utilizando um modelo de árvore de decisão relativamente simples com profundidade máxima limitada a cinco níveis e um número mínimo de 200 observações por folha. Além disso, foi aplicada uma ponderação das classes para lidar com o desbalanceamento do conjunto de dados. Esses parâmetros foram escolhidos intencionalmente para reduzir a complexidade do modelo, evitar sobreajuste e permitir uma análise inicial da importância das variáveis no fenômeno estudado.

A Figura 5 apresenta as 14 variáveis mais importantes segundo a árvore de decisão treinada para o problema de autoavaliação do estado de saúde. Observa-se que a variável Freq_Depressao concentra a maior parte da importância do modelo, seguida por Idade e por variáveis associadas à saúde mental, como Freq_Anedonia e Freq_Cansaco. Variáveis socioeconômicas e de estilo de vida, como posse de computador, prática de exercício físico e nível de instrução, apresentam contribuição intermediária, enquanto variáveis relacionadas a doenças e apoio social exibem importância residual.

Figura 5. Variáveis classificadas como mais importantes - Decision Tree

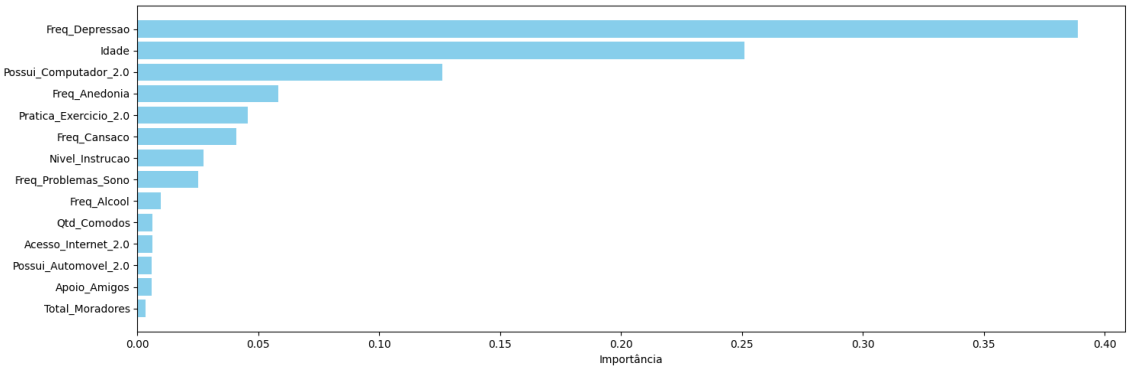

Apesar de fornecer indícios iniciais sobre fatores associados à autoavaliação do estado de saúde, os resultados obtidos com a árvore de decisão, apresentados na Figura 6, evidenciam limitações relevantes quando o problema é tratado como uma classificação ordinal multiclasse com cinco categorias. O modelo alcançou uma acurácia global de 31%, com valores de F1-score particularmente baixos nas classes extremas da escala, especialmente nas categorias “Muito Ruim” (0,12) e “Muito Boa” (0,34). Observa-se ainda uma tendência de confusão entre classes adjacentes, indicando dificuldade do modelo em capturar transições graduais entre os níveis da variável resposta.

Esse desempenho limitado decorre do fato de que a árvore de decisão utilizada trata as classes como categorias nominais independentes, desconsiderando a ordenação da autoavaliação do estado de saúde. Como consequência, erros entre categorias distantes e próximas são penalizados de forma equivalente, o que compromete a modelagem adequada do fenômeno. Dessa forma, os resultados obtidos com esse modelo devem ser interpretados como uma análise exploratória inicial, não constituindo o foco principal deste trabalho.

Figura 6. Métricas por Classe – Árvore de Decisão

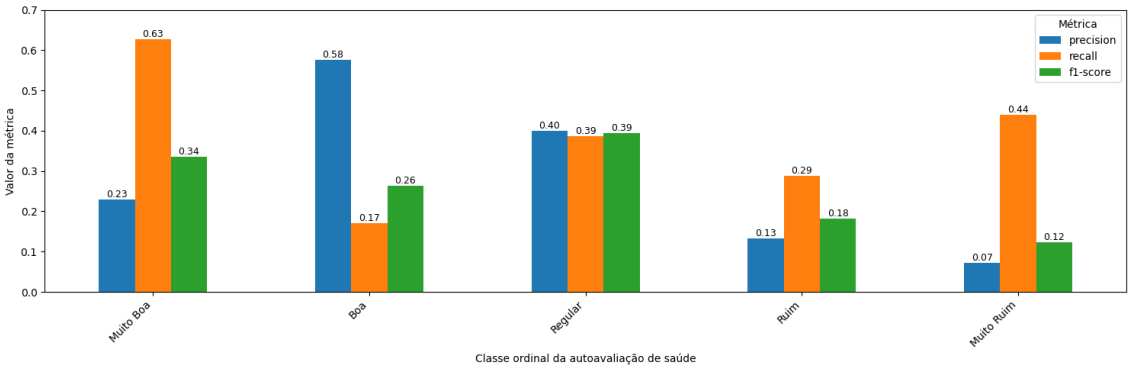

5.2. CatBoostRegressor

O *CatBoostRegressor* foi escolhido por sua capacidade de modelar relações não lineares e explorar a ordenação das categorias da autoavaliação de saúde, preservando informações ordinais. Nos experimentos, utilizou-se 800 iterações, profundidade máxima de 6, taxa de aprendizado de 0,05 e função de perda MAE, avaliando o desempenho com QWK, com divisão de 70% para treinamento e 30% para teste.

Como ilustrado na Figura 7, os experimentos foram conduzidos em quatro etapas distintas. Na primeira, o *CatBoostRegressor* foi treinado utilizando o conjunto de dados pré-processado completo. A segunda etapa consistiu em remover as variáveis de menor relevância identificadas pelo modelo de regressão logística, com o objetivo de simplificar o conjunto de atributos. Na terceira etapa, o algoritmo DBSCAN foi aplicado para agrupar registros mais coesos, selecionando 1.312 exemplos mais representativos a partir do total de 90.846 registros. Por fim, a quarta etapa combinou ambas as estratégias: o conjunto de dados clusterizado pelo DBSCAN foi refinado com a remoção das variáveis menos expressivas identificadas pela regressão logística. As variáveis com menor relevância foram Estado_Civil, Apoio_Familiar, Qtd_Comodos, Horas_TV e Fuma. Destas, apenas Estado_Civil, Apoio_Familiar e Qtd_Comodos foram efetivamente removidas, uma vez que Horas_TV e Fuma apresentam alta relevância em termos socioeconômicos e de saúde, justificando sua manutenção no conjunto final de atributos.

Os resultados dos experimentos realizados com o *CatBoostRegressor* estão apresentados na Tabela 5, com as métricas de Erro Absoluto Médio (MAE) e Quadratic Weighted Kappa (QWK). O primeiro teste, que utilizou o conjunto de dados completo com 25 variáveis, obteve um MAE de 0.48 e QWK de 0.40. Esses valores indicam um desempenho razoável, mas não ideal, especialmente quando comparados ao padrão esperado para problemas ordinais. A métrica MAE sugere uma média de erro relativamente alta nas previsões, enquanto o QWK mostra um desempenho moderado, refletindo uma captura parcial da relação ordinal entre as classes.

No segundo teste, foi realizada a remoção das variáveis menos relevantes identificadas pela regressão logística. Essa abordagem resultou em uma leve redução no MAE, que caiu para 0.47, e um pequeno aumento no QWK, que subiu para 0.41. Esses resultados indicam que a simplificação do modelo, ao remover atributos menos expressivos, teve

Figura 7. Fluxo de Experimentos

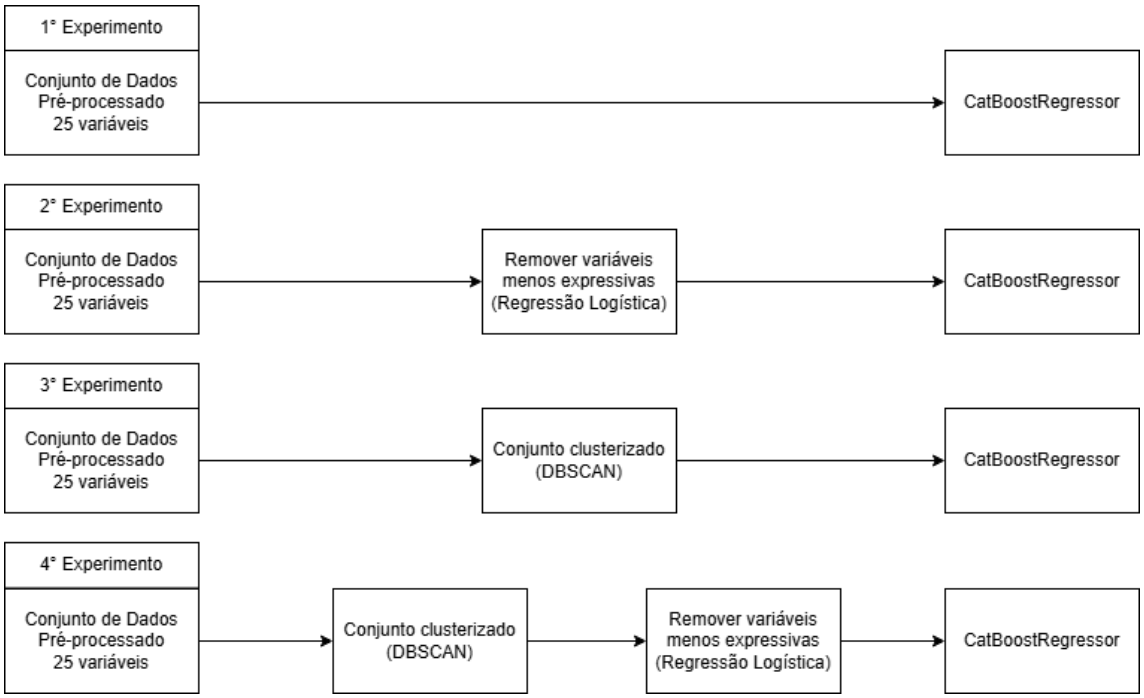

um impacto positivo na precisão das previsões, embora o efeito tenha sido modesto.

O terceiro teste aplicou a técnica de clusterização DBSCAN, com a intenção de selecionar os registros mais representativos. Essa abordagem levou a uma melhoria substancial nas métricas, com um MAE de 0.40 e QWK de 0.44. O uso do DBSCAN para reduzir a quantidade de dados e focar nos registros mais coesos permitiu ao modelo fazer previsões mais precisas, resultando em uma maior concordância entre as previsões e as classes reais.

Por fim, o quarto teste combinou a clusterização com a remoção das variáveis menos relevantes, aplicando a abordagem de seleção de atributos com base na regressão logística. Esse experimento obteve os melhores resultados, com um MAE de 0.39 e QWK de 0.45, superando os testes anteriores. O modelo, ao ser alimentado com um conjunto de dados mais enxuto e representativo, obteve um desempenho ainda melhor, tanto em termos de precisão quanto de captura das relações entre as classes, o que demonstra que a combinação de clusterização com a remoção de variáveis irrelevantes pode otimizar significativamente a performance do *CatBoost*.

Esses resultados indicam que, embora o modelo *CatBoostRegressor* tenha mostrado um bom desempenho geral, há espaço para melhorias, especialmente ao considerar técnicas como clusterização e a escolha criteriosa de variáveis. O uso de uma abordagem mais refinada de pré-processamento, como visto no terceiro e quarto testes, teve um impacto claro na precisão e na concordância ordinal, reforçando a importância dessas etapas para a consistência do modelo.

Na Figura 8, são apresentadas as variáveis mais importantes segundo o modelo *CatBoost* no experimento que obteve o melhor desempenho (4º experimento). Observa-

Tabela 5. Resultados dos Experimentos com *CatBoostRegressor*

Teste	MAE	QWK
Normal - 24 Features	0.48	0.40
Remover Variáveis (Logistic)	0.47	0.41
Normal - Clusterizado	0.40	0.44
Remover Variáveis - Clusterizado	0.39	0.45

se que a variável Idade foi a que mais impactou o modelo, indicando que o fator etário desempenha papel central na discriminação entre os diferentes níveis de autopercepção de saúde. Em seguida, destacam-se variáveis associadas a condições socioeconômicas e comportamentais, como Possui_Computador, Prática de Exercício e Possui_Automóvel, sugerindo que o acesso a bens, hábitos de vida ativos e condições materiais estão fortemente relacionados à forma como os indivíduos avaliam sua própria saúde.

Variáveis relacionadas ao bem-estar físico e mental, como Frequência de Problemas de Sono, Frequência de Cansaço, Frequência de Depressão e Frequência de Anedonia, também apresentaram relevância expressiva, reforçando a natureza multidimensional da autopercepção de saúde capturada pelos dados da PNS. Por outro lado, variáveis como Sexo, Fuma e algumas categorias de Cor/Raça apresentaram baixa importância relativa, indicando baixa contribuição para a interpretação final do fenômeno.

Figura 8. Top 20 Features - Importância pelo CatBoost

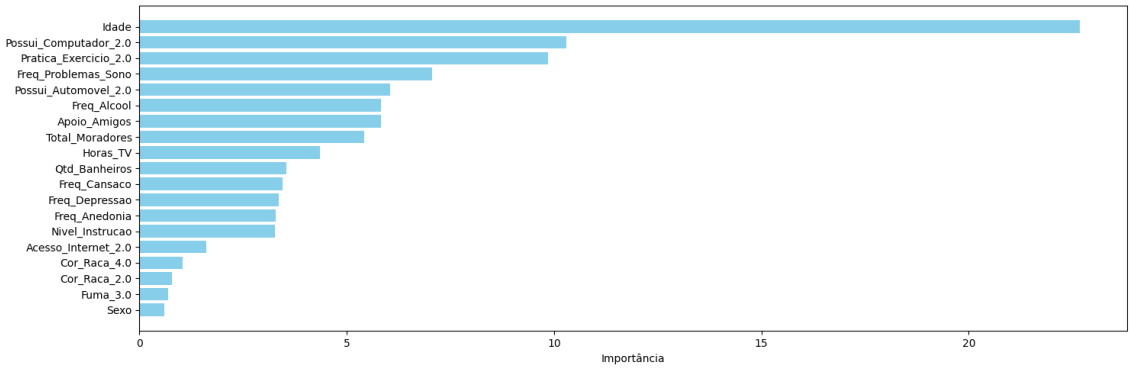

6. Discussão

Os experimentos com o *CatBoostRegressor* demonstraram bom desempenho na modelagem da autoavaliação do estado de saúde, superando a Árvore de Decisão (acurácia de 31%), embora métricas como MAE (0,39) e QWK (0,45) indiquem possibilidade de melhorias. A análise da importância das variáveis (Figura 8) revelou que fatores socioeconômicos, comportamentais e de saúde mental são centrais para a percepção individual de saúde. Destacam-se Idade, Possui_Computador, Pratica_Exercicio e Possui_Automovel, indicando que maior idade tende a associar-se a avaliações negativas, enquanto melhores condições socioeconômicas e hábitos saudáveis estão ligados a percepções mais positivas.

Além disso, variáveis relacionadas à saúde mental, como Problemas_Sono,

Freq_Cansaco, Freq_Depressao e Freq_Anedonia, mostraram grande relevância, indicando que dificuldades psicológicas impactam diretamente a percepção da saúde física. Em contraste, fatores como Sexo, Cor/Raca e Fuma tiveram menor importância, sugerindo que, neste conjunto de dados, outros determinantes socioeconômicos e comportamentais são mais indicativos da autoavaliação da saúde.

O modelo também demonstrou a eficácia das etapas de pré-processamento, como a clusterização DBSCAN e a remoção de variáveis irrelevantes, na melhoria das métricas de desempenho. A combinação desses procedimentos permitiu ao modelo trabalhar com dados mais representativos, resultando em previsões mais precisas e em uma melhor captura das relações entre as variáveis.

Trabalhos futuros podem explorar métodos automáticos de seleção de *features* para reduzir a complexidade da escolha manual de variáveis e permitir análises mais sistemáticas, além de investigar modelos estatísticos e de aprendizado de máquina mais interpretáveis para problemas ordinais, como *Ordinal Random Forest* ou *GAMs*. Também é recomendada a aplicação de técnicas de clusterização mais robustas, como *HDBSCAN*, para lidar melhor com variações de densidade, ruídos e aprimorar a caracterização de perfis de indivíduos nos modelos.

O *CatBoostRegressor* mostrou-se promissor para modelar a autoavaliação da saúde, destacando Idade, condições socioeconômicas e saúde mental como fatores-chave, enquanto sexo e raça tiveram menor impacto. A avaliação das métricas indicam espaço para melhorias na seleção de variáveis e otimização, refletindo a complexidade do fenômeno que envolve aspectos físicos, comportamentais e psicológicos. A continuidade desse estudo é essencial para fornecer análises que apoiem políticas públicas focadas em melhorar a qualidade de vida da população.

Referências

Ferrari Junior, G., Teixeira, C., and Felden, (2021). Socioenvironmental factors and behaviors associated with negative self-rated health in brazil. *Ciência Saúde Coletiva*, 26:4309–4320.

Szwarcwald, C. L., Damacena, G. N., de Souza Júnior, P. R., and et al. (2015). Determinants of self-rated health and the influence of healthy behaviors: results from the national health survey, 2013. *Revista Brasileira de Epidemiologia*, 18(Suppl 2):33–44.

Triaca, L., Franca, M. T., Guttier, M., and Tejada, C. A. (2017). Estilos de vida saudável e autoavaliação de saúde como boa: uma análise dos dados da pns/2013. *Jornal Brasileiro de Economia da Saúde*, 9(3):260–266.

Zong, X., Nelimarkka, M., Martikainen, P., and Silventoinen, K. (2025). Predicting later-life self-rated health from childhood living conditions using machine learning approach.

Zárate, L., Petrocchi, B., Dias Maia, C., Felix, C., and Gomes, M. (2023). Capto - a method for understanding problem domains for data science projects: Capto - um método para entendimento de domínio de problema para projetos em ciência de dados. *Concilium*, 23:922–941.